Análise das variáveis Saeb - moda por escola Série 9EF

Livia Kobayashi

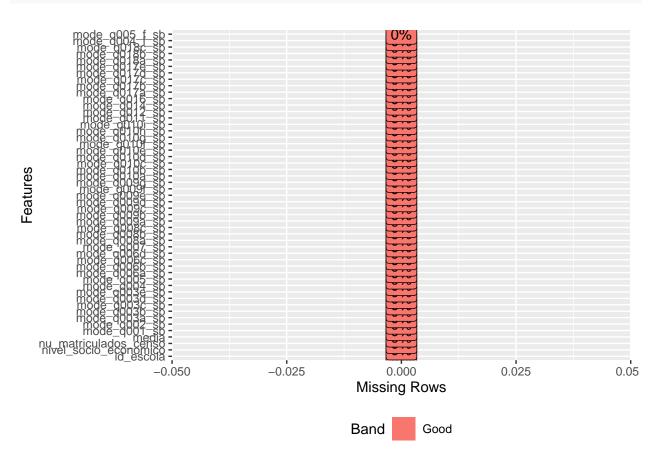
14 junho 2021

A tibble: 1 x 2
Groups: id_serie [1]
id_serie n
<chr> <int>
1 9EF 4636

Missing

Base 100% preenchida

plot_missing(df)

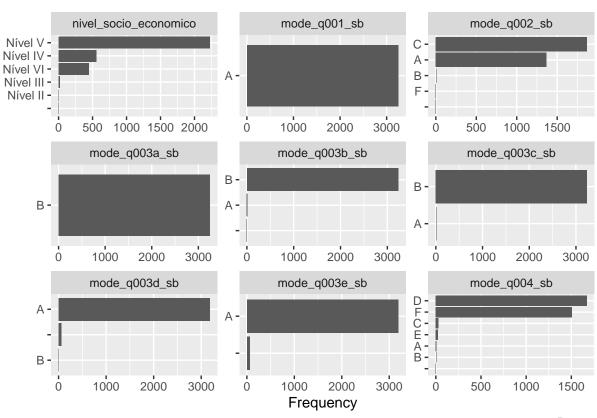


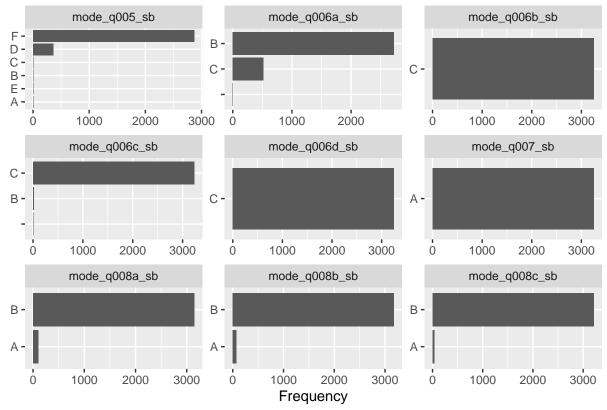
Volume

Variáveis com baixa variância:

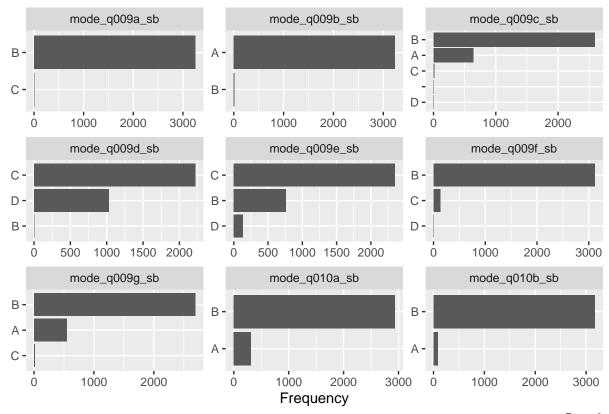
- $mode_q001_sb mode_q003a_sb mode_q003b_sb mode_q003c_sb$
- $\bullet \quad mode_q003d_sb mode_q003e_sb mode_q006b_sb$
- $mode_q008b_sb mode_q008c_sb mode_q009a_sb mode_q009b_sb$
- $\bullet \quad mode_q009f_sb mode_q010b_sb mode_q010e_sb mode_q010f_sb$
- $mode_q010h_sb mode_q010i_sb mode_q011_sb mode_q014_sb$
- $\bullet \quad mode_q004_f_sb mode_q005_f_sb$

plot_bar(final_data)

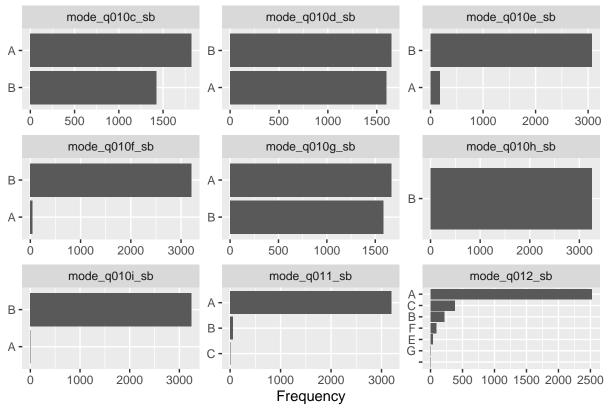




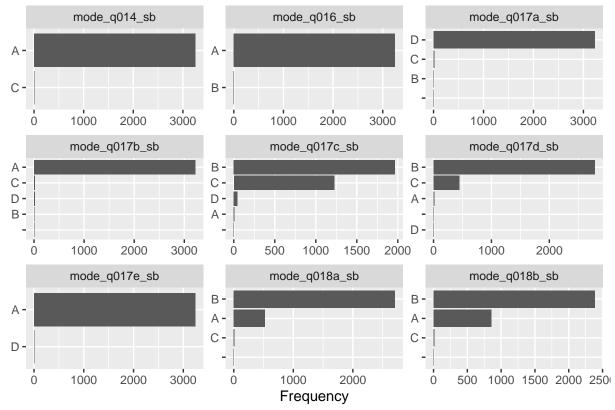
Page 2



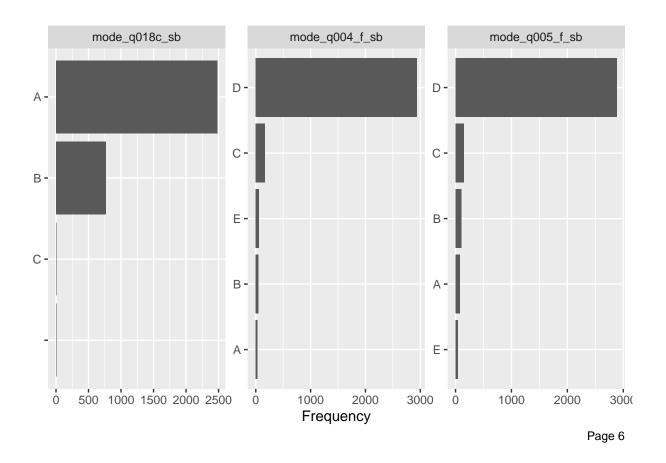
Page 3



Page 4



Page 5



Médias das notas x variáveis

Variáveis que discriminam e tem volume nas categorias:

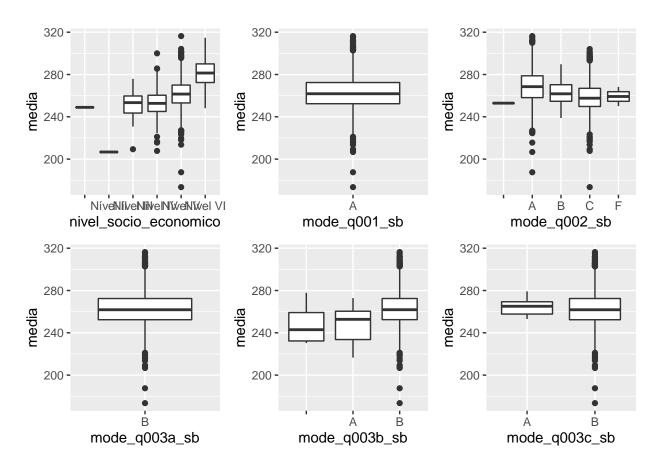
- mode_q002_sb: Maioria branca => notas maiores
- mode_q004_sb: maior graduação => notas maiores (agrupar A, B e C)
- mode_q005_sb: maior graduação => notas maiores (agrupar A, B e C)
- $mode_q006a_sb$: Os pais conversarem sobre a escola => notas >
- $mode_q009c_sb: \# computador => notas >$
- $mode_q009d_sb: \# Quartos => notas >$
- $mode_q009g_sb: \# Carro => Notas >$
- $mode_q010c_sb$: Ter um quarto só para si => notas >
- $mode_q010g_sb: Ter aspirador => Notas >$

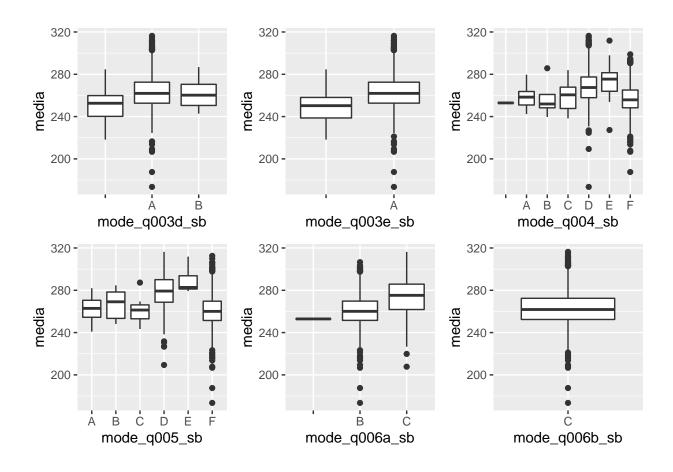
- mode_q017c_sb: menos tempo gasto em tarefas domésticas => notas > (Isolar o A e juntar as outras)
- $mode_q017d_sb$: Não usar!!!
- mode_q018a_sb: Leitura notícias => notas >

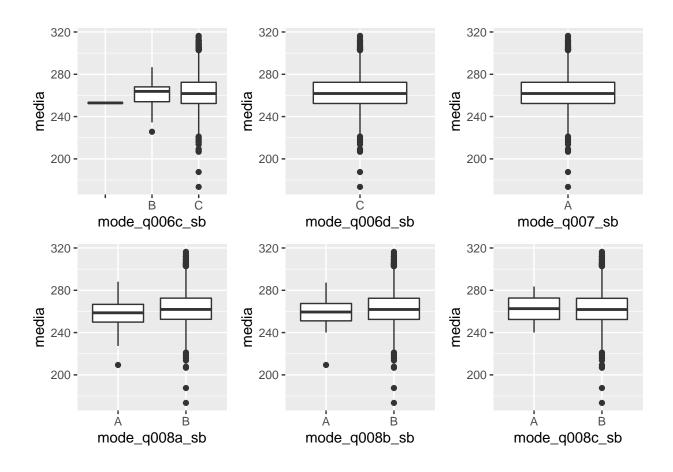
```
vars <- colnames(final_data)
vars <- vars[-c(1,2)]
plots <- list()
i <- 1
for (variable in vars) {
    plots[[i]] <- ggplot(final_data, aes_string(variable, "media")) + geom_boxplot()
    i <- i + 1
}

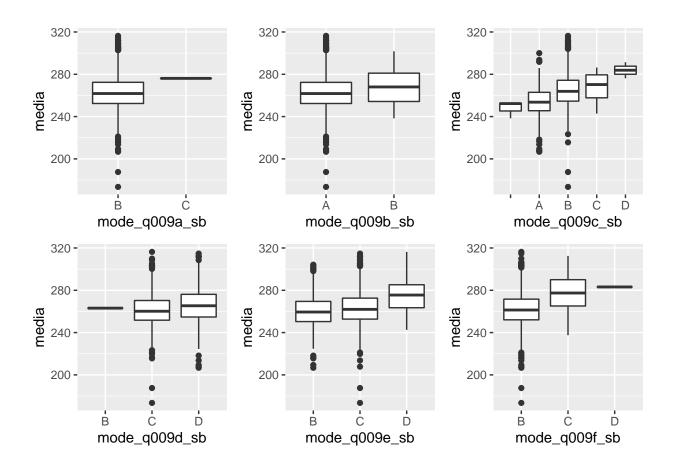
n <- length(plots)

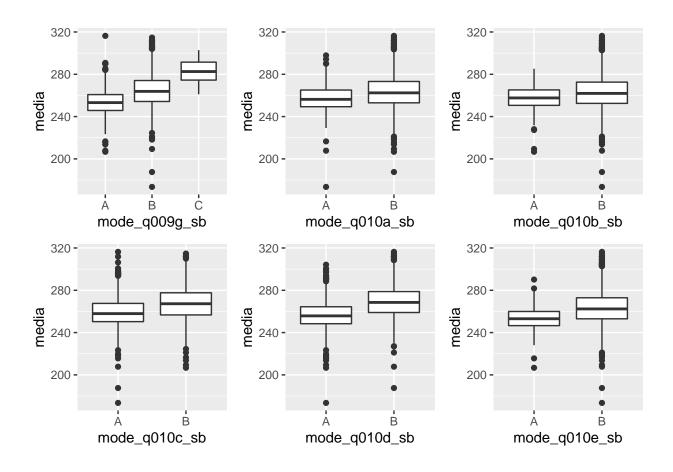
i <- 1
while (i <= n) {
    do.call("grid.arrange", c(plots[i:(min(i+5, n))], ncol=3, nrow = 2))
    i <- i + 6
}</pre>
```

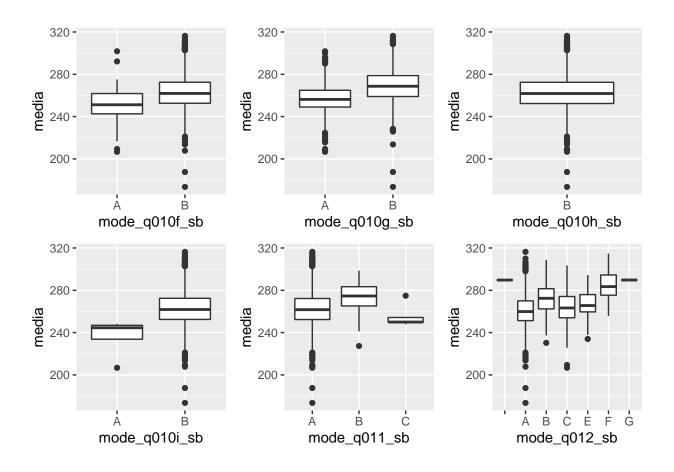


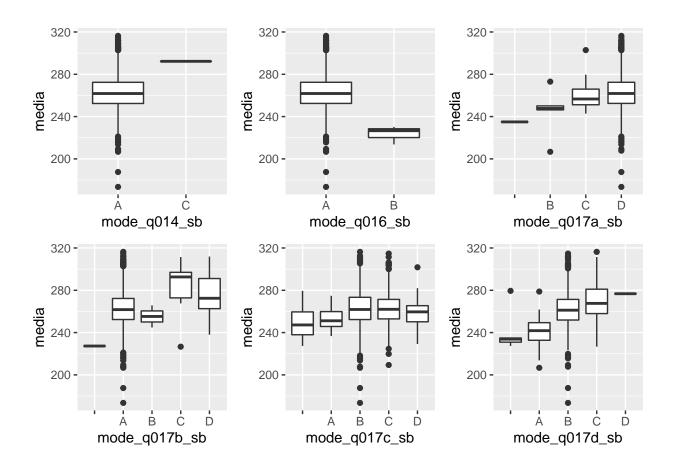


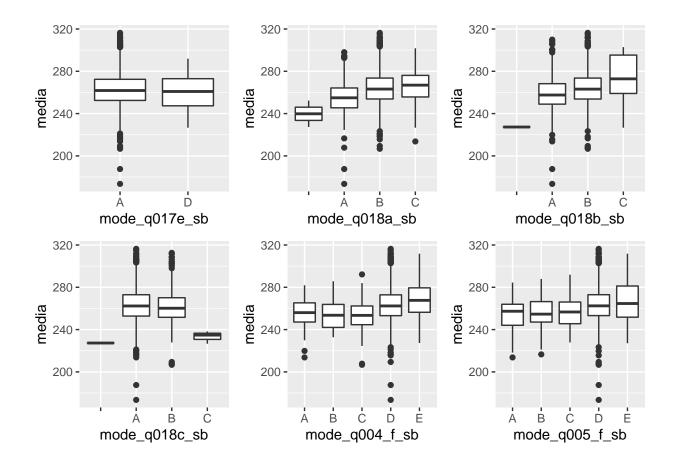












Análise Univariada

Variáves mais significativas

- $mode_q010d_sb$: Na sua casa tem: Mesa para estudar (ou escrivaninha).
- mode_q010g_sb: Na sua casa tem: Aspirador de pó.
- mode_q004_sb: Qual é a maior escolaridade da sua mãe (ou homem responsável por você)?
- mode q005 sb: Qual é a maior escolaridade de seu pai (ou homem responsável por você)?
- mode_q002_sb: Qual é a sua cor ou raça?

```
vars <- colnames(final_data)
vars <- vars[-c(1,2)]
y_resp <- "media"

remove_cols <- nearZeroVar(df, names = TRUE)
final_cols <- setdiff(vars, remove_cols)
final_cols</pre>
```

```
"mode_q004_sb"
##
    [1] "nivel_socio_economico"
                                 "mode_q002_sb"
       "mode_q005_sb"
                                  "mode_q006a_sb"
                                                           "mode_q009c_sb"
##
##
    [7]
        "mode_q009d_sb"
                                  "mode_q009e_sb"
                                                           "mode_q009g_sb"
   [10]
        "mode_q010a_sb"
                                                           "mode_q010d_sb"
##
                                 "mode_q010c_sb"
   [13] "mode_q010e_sb"
                                 "mode q010g sb"
                                                           "mode_q012_sb"
   [16] "mode_q017c_sb"
                                 "mode_q017d_sb"
                                                           "mode_q018a_sb"
```

```
## [19] "mode_q018b_sb"
                                  "mode_q018c_sb"
                                                            "mode_q004_f_sb"
tb_r2 <- data.frame(var = final_cols)</pre>
rsquared <- c()
for (variable in final_cols) {
  lm_formula <- as.formula(str_glue("{y_resp} ~ {variable}"))</pre>
  model_lm <- lm(lm_formula, df)</pre>
  rsquared <- append(rsquared, summary(model_lm)$r.squared)</pre>
tb_r2$rsquared <- rsquared
tb_r2 %>% head(nrow(tb_r2))
##
                         var
                                 rsquared
## 1
      nivel_socio_economico 0.287490203
## 2
                mode_q002_sb 0.118057451
## 3
                mode_q004_sb 0.147387248
## 4
                mode_q005_sb 0.146574773
## 5
               mode_q006a_sb 0.093063661
## 6
               mode_q009c_sb 0.081653538
## 7
               mode_q009d_sb 0.019547723
## 8
               mode_q009e_sb 0.032252272
               mode_q009g_sb 0.076896075
## 9
               mode_q010a_sb 0.015054748
## 10
## 11
               mode_q010c_sb 0.078102130
## 12
               mode_q010d_sb 0.178500540
## 13
               mode_q010e_sb 0.021772217
## 14
               mode_q010g_sb 0.157889326
## 15
                mode_q012_sb 0.098162103
## 16
               mode_q017c_sb 0.003419567
```

MAtriz de correlação

mode_q017d_sb 0.044289720

mode_q018a_sb 0.046041453

mode_q018b_sb 0.027737271

mode_q018c_sb 0.006930552 mode_q004_f_sb 0.029834656

17

18

19

20

21

- mode_q002_sb (raça) e mode_q006a_sb (pais conversam com os filhos) => manter mode_q002_sb ou combinar ambas
- mode_q004_sb (escolaridade mãe) e mode_q006a_sb (pais conversam com os filhos) => manter mode_q004_sb ou combinar ambas
- mode_q018b_sb (leitura livros) e mode_q018c_sb (leitura em quadrinhos) => baixo r2

```
catcorrm <- function(vars, dat) sapply(vars, function(y) sapply(vars, function(x) assocstats(table(dat[
matriz <- catcorrm(final_cols, data_corr)

ggcorrplot(matriz, show.diag = F, type="lower", lab=TRUE, lab_size=6, show.legend = F)</pre>
```

